

Tarea 2

Julián Rojas

jrojasj@usm.cl

Profesores: Nicolás Viaux & Ariel Norambuena

Ayudante: Cristóbal Benavides

Problema 1: Inteligencia artificial para problemas inversos

(a)

Dificultades del problema inverso. Mientras que el problema directo relaciona unos parámetros fijos (γ, k) para obtener la curva temporal $x(t)$ de forma estable, el problema inverso va al revés ($x(t) \rightarrow (\gamma, k)$) y suele ser muy inestable por los siguientes motivos:

- **Degeneración y acoplamiento:** La frecuencia de oscilación depende de ambos parámetros a la vez mediante $\omega_d = \sqrt{k - \gamma^2/4}$. Esto genera que distintas combinaciones de k y γ den curvas de posición casi idénticas, por lo que se pierde la unicidad de la solución si los datos de entrada tienen ruido o están incompletos.
- **Sensibilidad frente al ruido:** El proceso de inversión no es continuo. El ruido experimental en los datos de la señal interfiere con el cálculo de las derivadas implícitas, lo que hace que los errores se amplifiquen fuertemente al intentar predecir los parámetros originales.

Aprendizaje supervisado y función de pérdida. En el aprendizaje supervisado buscamos aproximar la función inversa mediante una red neuronal con pesos entrenables Θ . El objetivo es ajustar estos pesos minimizando una función de pérdida sobre los datos de entrenamiento:

$$\Theta^* = \arg \min_{\Theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\Theta}(\mathbf{x}_i), \theta_i). \quad (1)$$

Para calcular variables continuas como (γ, k) , se utiliza el Error Cuadrático Medio (MSE):

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N \left[(\gamma_i - \hat{\gamma}_i)^2 + (k_i - \hat{k}_i)^2 \right]. \quad (2)$$

El uso del MSE es el estándar ya que es una función diferenciable en todo su dominio (lo que por ejemplo permite usar gradient descend) y equivale a buscar la máxima verosimilitud asumiendo que los errores de medición tienen una distribución gaussiana.

Para poder entrenar así, es obligatorio tener las etiquetas verdaderas θ_i . El modelo necesita esta referencia para calcular los errores y corregir sus parámetros internos con el backpropagation. Si no tuviéramos estas etiquetas, estaríamos ante un problema no supervisado.

Fundamentos de PINNs. Las Redes Neuronales Informadas por la Física (PINNs) reducen la cantidad de datos experimentales necesarios al incluir las ecuaciones del sistema dentro del entrenamiento. De esta forma, la función de pérdida total combina los datos con la parte física de la EDO:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{data}} + \lambda \mathcal{L}_{\text{PDE}}, \quad (3)$$

donde el error asociado a la ecuación diferencial se evalúa en puntos específicos llamados puntos de colocación $\{t_j\}$:

$$\mathcal{L}_{\text{PDE}} = \frac{1}{N_c} \sum_{j=1}^{N_c} \left[\ddot{x}(t_j) + \hat{\gamma} \dot{x}(t_j) + \hat{k} x(t_j) \right]^2. \quad (4)$$

Las derivadas temporales $\dot{x}$ y $\ddot{x}$ se obtienen sin aproximaciones numéricas usando diferenciación automática. El parámetro λ regula el peso de la física en el entrenamiento: si $\lambda \rightarrow 0$ el modelo solo sigue los datos visuales, mientras que si es muy grande, se prioriza que se cumpla estrictamente la ecuación del oscilador.

Entrenamiento vs. Validación. Separar el dataset en grupos de entrenamiento y validación permite ver si el modelo realmente aprendió o solo memorizó. El error de entrenamiento muestra qué tan bien se adapta la red a los datos conocidos, mientras que el error de validación mide el desempeño real con datos nuevos que nunca vio en el entrenamiento.

(b) Generación del dataset y análisis de señales

Se creó un conjunto de curvas de osciladores variando los parámetros en sus rangos lógicos. Para simular datos reales de un laboratorio, se agregó ruido gaussiano a las señales obtenidas.




Figura 1: Muestras del dataset para el oscilador armónico amortiguado. Se presentan seis escenarios variando de manera cruzada γ y k para contrastar las curvas ideales frente a las señales ruidosas.

Al mirar los gráficos de la Figura 1, se puede notar que los dos parámetros afectan la forma de la señal de maneras muy diferentes:

- **Efecto de k :** Modifica la frecuencia de oscilación (ω_d). En los casos con k alto vemos más ciclos dentro del tiempo medido ($t \in [0, 10]$), lo que le da al modelo más patrones visuales claros para poder identificar su valor.
- **Efecto de γ :** Controla la caída exponencial de la amplitud ($e^{-\gamma t/2}$). Si γ es muy grande, la oscilación desaparece muy rápido al principio del gráfico, haciendo que se pierda la información útil en el resto de la ventana de tiempo.

(c) Entrenamiento de modelos y evaluación del desempeño

Se usaron los datos de entrenamiento y prueba para evaluar un Random Forest y un mMultilayer Perceptron (MLP), usando la métrica RMSE en un entorno con nivel de ruido fijo ($\sigma = 0.02$).

Random Forest: Este modelo entrenado con las series de tiempo dio resultados bastante precisos y cercanos a los valores reales:

$$\text{RMSE}_{\gamma}^{\text{RF}} = 0.0162, \quad \text{RMSE}_k^{\text{RF}} = 0.0206. \quad (5)$$

Multilayer Perceptron (MLP): Red densa programada en PyTorch y optimizada usando MSE con escala logarítmica durante 80 épocas:

$$\text{RMSE}_{\gamma}^{\text{MLP}} = 0.0173, \quad \text{RMSE}_k^{\text{MLP}} = 0.0759. \quad (6)$$




Figura 2: Evolución temporal de las curvas de pérdida (MSE) del Perceptrón Multicapa en escala logarítmica para los conjuntos de entrenamiento y validación.

En la Figura anterior podemos ver que el error baja muy rápido en las primeras épocas y se estabiliza cerca de la época 20. Un punto interesante es que la pérdida de validación quedó por debajo de la de entrenamiento ($\text{MSE}_{\text{val}} < \text{MSE}_{\text{train}}$), lo que se debe a que el Dropout está encendido solo al entrenar.




Figura 3: Gráficos de dispersión para las predicciones frente al valor real ($\sigma = 0.02$) correspondientes al Random Forest y al MLP.

Se encontró que el Random Forest funcionó mucho mejor que el MLP para aproximar el parámetro k . Sus puntos están bien agrupados sobre la línea ideal $y = x$, mientras que el MLP muestra mucha dispersión y tiende a subestimar los valores más altos de k ($k > 4.5$).

(d) Efecto del nivel de ruido sobre la inferencia de parámetros

Para probar la resistencia de ambos modelos, se aumentó el nivel de ruido de forma gradual en un rango de $\sigma \in [0.0, 0.10]$.




Figura 4: Curvas de sensibilidad de la métrica RMSE en función de la amplitud del ruido (σ) para la constante de amortiguamiento γ y de rigidez k .

Los resultados de la Figura 4 muestran el comportamiento de cada algoritmo:

- El error en el Random Forest sube en línea recta a medida que aumentamos el ruido σ , lo que demuestra que es un modelo bastante estable frente a las variaciones del dataset.
- En el MLP ocurre algo curioso: cuando no hay nada de ruido ($\sigma = 0.0$), el error al predecir k es más alto (~ 0.061) que cuando hay un poco de ruido como $\sigma = 0.01$ (~ 0.039). Esto pasa porque el ruido actúa como un regulador que ayuda a evitar que la red se sobreajuste.

Problema 2: Terapia con protones: simulación Monte Carlo del pico de Bragg

(a) Marco teórico y transporte de carga

Al contrario de lo que ocurre con los fotones, los protones dejan la mayor parte de su energía casi al final de su camino, en una zona muy localizada que se conoce como el pico de Bragg. La pérdida media de energía por distancia recorrida se calcula con la ecuación relativista de Bethe-Bloch:

$$-\frac{dE}{dx} = Kz^2 \frac{Z}{A} \frac{1}{\beta^2} \left[\frac{1}{2} \ln \frac{2m_e c^2 \beta^2 \gamma_L^2 T_{\text{máx}}}{I^2} - \beta^2 \right]. \quad (7)$$

El término $1/\beta^2$ pesa mucho en este proceso debido al tiempo que dura la interacción. Cuando el protón va muy rápido, pasa de largo casi sin interactuar con los electrones. Pero a medida que frena ($\beta \rightarrow 0$), pasa más tiempo cerca de los átomos, lo que aumenta la probabilidad de ionización y hace que libere casi toda su energía de golpe justo antes de detenerse por completo.

(b) Poder de frenado y aproximación CSDA

Integrando numéricamente la ecuación de Bethe-Bloch se obtuvo el poder de frenado y el rango total usando la aproximación de frenado continuo (CSDA), para luego comparar los valores con las tablas oficiales PSTAR del NIST.




Figura 5: Simulación del poder de frenado electrónico y rango CSDA para protones en agua ($I = 75$ eV). El panel izquierdo muestra la curva de Bethe-Bloch en escala logarítmica. El panel derecho despliega el rango integrado R_{CSDA} frente a la energía inicial del haz E_0 .

Las curvas de la Figura 5 muestran que el código desarrollado funciona correctamente, dando valores de rango prácticamente idénticos a los del NIST para las energías evaluadas:

- Para $E_0 = 50$ MeV: $R_{\text{calc}} = 2.2$ cm (NIST = 2.2 cm).
- Para $E_0 = 150$ MeV: $R_{\text{calc}} = 15.8$ cm (NIST = 15.8 cm).
- Para $E_0 = 250$ MeV: $R_{\text{calc}} = 37.9$ cm (NIST = 38.0 cm).

(c) Perfil de dosis y efectos del Straggling de Bohr

Para hacer una simulación más realista, se armó un código Monte Carlo que incluye las fluctuaciones estadísticas de la pérdida de energía (*energy straggling*) usando la teoría de Bohr con una distribución gaussiana. Se simuló el comportamiento de 10,000 protones entrando en agua con una energía inicial de $E_0 = 150$ MeV.




Figura 6: Perfiles de deposición de dosis espacial obtenidos por simulación Monte Carlo para $E_0 = 150$ MeV y 10,000 protones ($\Delta x = 0.1$ mm).

Al mirar el gráfico de la Figura 6 se nota cómo cambia el perfil al meter estas fluctuaciones. En el caso determinista (sin straggling), toda la energía se concentra en una posición fija, dejando un pico muy afilado a los $z = 157.6$ mm, lo que calza con el valor teórico de $R_{\text{CSDA}} = 157.5$ mm.

En cambio, al activar el modelo de Bohr para simular las colisiones aleatorias, la curva se ensancha y toma una forma gaussiana con una desviación estándar de $\sigma_R = 7.39$ mm. Esto hace que la altura máxima del pico baje un poco y que el punto de máxima dosis se mueva ligeramente hacia atrás, quedando en $z = 145.8$ mm.




Figura 7: Comparativa directa de los perfiles de dosis normalizados al 100 % de su intensidad máxima para las simulaciones determinista y estocástica con Straggling de Bohr ($E_0 = 150.0$ MeV).

Por último, el gráfico de la Figura 7 ilustra el problema real al planificar tratamientos

médicos. Con un haz ideal, la dosis en la entrada es muy baja ($\sim 4\%$) y todo el impacto se va al tumor al final del recorrido. Sin embargo, debido al straggling físico que ocurre en la realidad, la dosis en los tejidos sanos del principio sube hasta casi un 20% del máximo, y la caída después del pico se vuelve más suave, algo que se debe tener en cuenta al diseñar las terapias.